



# PLN: beyond prediction and theory

LSD

Bastien Batardière

11 février 2025



LICENCE OUVERTE  
OPEN LICENCE

## ► Aperçu

- Normalité asymptotique et inférence variationnelle
- Optimisation et inférence variationnelle



# Section 1

## Contexte et introduction

---



## ► Contexte

### Données

$\mathbf{Y} \in \mathbb{R}^{n \times p}$  :  $n$  individus  $\mathbf{Y}_i$  indépendants, de dimension  $p$ .

### Modèle à variables latentes

$$\begin{aligned}\mathbf{Z}_i &\stackrel{\text{indep}}{\sim} p_{\theta}(\cdot) \\ Y_{ij} | Z_{ij} &\stackrel{\text{indep}}{\sim} p_{\theta}(\cdot | Z_{ij})\end{aligned}$$

### Vraisemblance

$$p_{\theta}(\mathbf{Y}_i) = \int_{\mathbb{R}^p} p_{\theta}(\mathbf{Y}_i, \mathbf{Z}_i) d\mathbf{Z}_i$$

## ► Modèle Poisson Log Normal

### Modèle

- Etant donné des covariables :
  - $\mathbf{x}_i$  covariables de taille  $m$  pour  $i = \{1, \dots, n\}$  (longueur de la séquence d'ADN, température, etc)
- un paramètre  $\theta = (\mathbf{B}, \Sigma)$  :
  - $\mathbf{B} \in \mathbb{R}^{m \times p}$  un paramètre de régression
  - $\Sigma \in \mathcal{S}_p^{++}$  une matrice de covariance

$$\mathbf{Z}_i \stackrel{\text{indep}}{\sim} \mathcal{N}(\mathbf{x}_i^\top \mathbf{B}, \Sigma)$$

$$Y_{ij} | Z_{ij} \stackrel{\text{indep}}{\sim} \mathcal{P}(\exp\{Z_{ij}\})$$

## ► Enjeux

### Maximisation de la log vraisemblance

$$\hat{\theta}^{\text{MLE}} = \operatorname{argmax}_{\theta} \log p_{\theta}(\mathbf{Y}) = \operatorname{argmax}_{\theta} \sum_{i=1}^n \log p_{\theta}(\mathbf{Y}_i)$$

- Comment approcher  $\hat{\theta}^{\text{MLE}}$  efficacement ?
- Quelles garanties ?

### Garanties de $\hat{\theta}^{\text{MLE}}$

$$\sqrt{n} \left( \hat{\theta}^{\text{MLE}} - \theta^{\star} \right) \xrightarrow{d} \mathcal{N}(0, \mathcal{I}(\theta^{\star})^{-1})$$

## ► Rappel sur l'inférence variationnelle

- Log vraisemblance intractable
  - Estimation problématique
  - Approche alternative: approximation
- Borne inférieure de la vraisemblance (ELBO) :

$$J_{\mathbf{Y}}(\theta, \phi) \triangleq \log p_{\theta}(\mathbf{Y}) - \text{KL} [\tilde{p}_{\phi}(\cdot) \| p_{\theta}(\cdot | \mathbf{Y})]$$

avec  $\tilde{p}_{\phi}$  une distribution variationnelle connue approchant  $p_{\theta}(\cdot | \mathbf{Y})$ .

- Estimateur variationnel

$$\hat{\theta}^{\text{VEM}} = \operatorname{argmax}_{\theta, \phi} J_{\mathbf{Y}}(\theta, \phi)$$



## ► Choix de la famille variationnelle

### Famille gaussienne diagonale

$$\tilde{p}_{\phi_i} = \mathcal{N}(\mathbf{m}_i, \text{Diag}(\mathbf{s}_i^2)), \quad \phi_i = (\mathbf{m}_i, \mathbf{s}_i), \quad \mathbf{m}_i \in \mathbb{R}^p, \mathbf{s}_i \in \mathbb{R}^q, \quad (1)$$

$$\phi = (\phi_1, \dots, \phi_n) = (\mathbf{m}_1, \dots, \mathbf{m}_n, \mathbf{s}_1, \dots, \mathbf{s}_n)$$



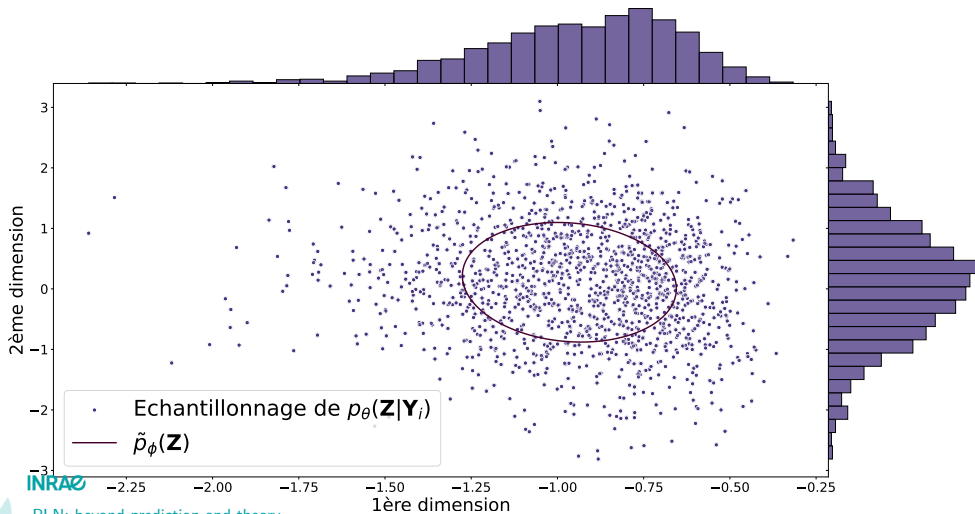
## ► Un peu d'intuition

### ► ELBO:

$$J_{\mathbf{Y}}(\theta, \phi) = \log p_{\theta}(\mathbf{Y}) - \text{KL} [\tilde{p}_{\phi}(\cdot) \| p_{\theta}(\cdot | \mathbf{Y})] \quad (2)$$

$$= \mathbb{E}_{\tilde{p}_{\phi}} [\log p_{\theta}(\mathbf{Y}, \mathbf{Z}) - \log \tilde{p}_{\phi}(\mathbf{Z})] \quad (3)$$

## ► Un peu d'intuition



## Section 2

# Optimisation et inférence variationnelle

---



## ► Optimisation et inférence variationnelle

### Objectif

$$\hat{\theta}^{\text{VEM}}, - = \operatorname{argmax}_{\theta, \phi} J_{\mathbf{Y}}(\theta, \phi)$$

### Leviers

- Changement de paramétrisation
- Méthodes d'optimisations

## ► Algorithme Variational EM (VEM)

### ► EM Variationnel (VEM) :

- Maximisation alternée de  $J_{\mathbf{Y}}(\theta, \phi)$ .

Etape VE :

$$\phi^{(t)} = \operatorname{argmax}_{\phi} J_{\mathbf{Y}}(\theta^{(t)}, \phi)$$

Etape de maximisation (M) :

$$\theta^{(t+1)} = \operatorname{argmax}_{\theta} J_{\mathbf{Y}}(\theta, \phi^{(t)})$$

- $J_{\mathbf{Y}}(\theta^{(t+1)}, \phi^{(t+1)}) > J_{\mathbf{Y}}(\theta^{(t)}, \phi^{(t)})$
- Maximisation alternée de  $J_{\mathbf{Y}}(\theta, \phi)$ .
- Un problème d'optimisation à chaque itération
- Très coûteux



## ► Différentes paramétrisations

Paramétrisations équivalentes du modèle PLN:

$$Y_{ij}|Z_{ij} \sim \mathcal{P}(\exp(Z_{ij})),$$

$$Y_{ij}|Z_{ij} \sim \mathcal{P}(\exp(\mathbf{B}_j^\top \mathbf{X}_i + Z_{ij})),$$

$$Y_{ij}|\mathbf{Z}_i \sim \mathcal{P}(\exp(\mathbf{B}_j^\top \mathbf{x}_i + \mathbf{C}_j^\top \mathbf{Z}_i)),$$

$$\mathbf{Z}_i \sim \mathcal{N}(\mathbf{B}^\top \mathbf{x}_i, \Sigma), \quad (\text{PLN-closed})$$

$$\mathbf{Z}_i \sim \mathcal{N}(\mathbf{0}_p, \Sigma), \quad (\text{PLN-0})$$

$$\mathbf{Z}_i \sim \mathcal{N}(\mathbf{0}_p, \mathbf{I}_p). \quad (\text{PLN-PF})$$



## ► Formes close

En fonction de la paramétrisation, l'étape de maximisation peut être plus ou moins complexe.

- PLN-closed: Forme close sur  $\mathbf{B}$  et  $\Sigma$
- PLN-0: Forme close pour  $\mathbf{B}$
- PLN-PF: Aucune forme close

## ► Approche brutale

- Montée de gradient directe:

$$\theta^{(t+1)}, \phi^{(t+1)} = (\theta^{(t)}, \phi^{(t)}) + \eta_t \nabla_{\theta, \phi} (J_{\mathbf{Y}}(\theta^{(t)}, \phi^{(t)}))$$

$\eta_t > 0$  : pas d'apprentissage.

- Pas de garantie sur le signe de  $J_{\mathbf{Y}}(\theta^{(t+1)}, \phi^{(t+1)}) - J_{\mathbf{Y}}(\theta^{(t)}, \phi^{(t)})$
- Convergence plus rapide en pratique, avec le bon optimiseur (choix de  $\eta_t$ ).
- Très bon résultat avec l'optimiseur Rprop.



## ► Approche mixte profilé

- Si l'étape E est une forme close :  $(\mathbf{B}^{(t+1)}, \Sigma^{(t+1)}) = H(\phi)$  avec

$$\nabla_{\theta} J(\theta, \phi) |_{\theta=H(\phi)} = 0.$$

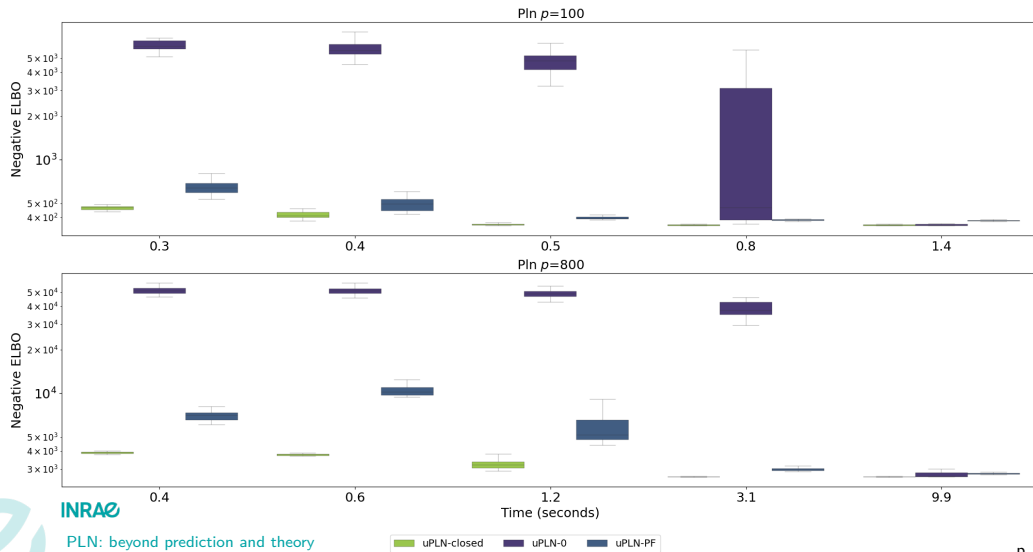
- On peut définir l'ELBO profilé

$$\tilde{J}_{\mathbf{Y}}(\phi) = J_{\mathbf{Y}}(H(\phi), \phi)$$

- Réduction drastique du nombre de paramètres
- Gagne une inversion de matrice



## ► Simulations



## Section 3

### Normalité asymptotique (Soumis à JCGS)

---

## ► Garanties de $\hat{\theta}^{\text{VEM}}$

### ► ELBO:

$$J_{\mathbf{Y}}(\theta, \phi) = \log p_{\theta}(\mathbf{Y}) - \text{KL} [\tilde{p}_{\phi}(\cdot) \| p_{\theta}(\cdot | \mathbf{Y})] \quad (4)$$

$$= \mathbb{E}_{\tilde{p}_{\phi}} [\log p_{\theta}(\mathbf{Y}, \mathbf{Z}) - \log \tilde{p}_{\phi}(\mathbf{Z})] \quad (5)$$

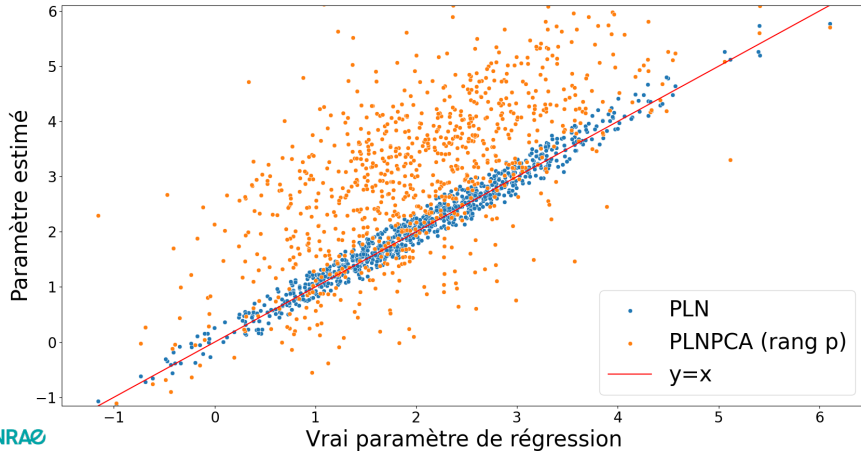
### ► Estimateur variationnel

$$\hat{\theta}^{\text{VEM}}, \hat{\phi} = \operatorname{argmax}_{\theta, \phi} J_{\mathbf{Y}}(\theta, \phi)$$


### ► Quelles garanties sur $\hat{\theta}^{\text{VEM}}$ ?

$$\sqrt{n} (\hat{\theta}^{\text{VEM}} - \theta^{\star}) \xrightarrow{d} ?$$

## ► Estimateur biaisé ?



## ► Estimation du biais



INRAE

PLN: beyond prediction and theory  
Bastien Batardière

--  $y = 2.2/\sqrt{n}$



$\text{RMSE}(\hat{B} - B^*)$



$\text{RMSE}(\hat{\Sigma} - \Sigma^*)$

## Section 4

### Estimateur de la variance

---

## ► Estimateur de la variance

Fonction objective profilé

$$L(\theta; \mathbf{Y}) \triangleq \sup_{\phi} J_{\mathbf{Y}}(\theta, \phi) = J_{\mathbf{Y}}(\theta, \hat{\phi})$$



## ► Estimateur naïf de la variance

- Pour l'estimateur du maximum de vraisemblance:

$$\sqrt{n} \left( \hat{\theta}^{\text{MLE}} - \theta^* \right) \xrightarrow{d} \text{mathcal{N}}(0, \mathcal{I}(\theta^*)^{-1})$$

- Si  $\hat{\theta}^{\text{VEM}}$  est assez proche de  $\theta^*$ , on peut approximer  $\mathcal{I}(\theta^*)$  par  $\mathcal{I}(\hat{\theta}^{\text{VEM}})$ .

$$\begin{aligned} \mathcal{I}(\hat{\theta}^{\text{VEM}}) &\approx -\frac{1}{n} \nabla_{\theta}^2 \log p_{\theta}(\mathbf{Y}) \\ &\approx -\frac{1}{n} \nabla_{\theta}^2 L(\theta) \end{aligned}$$

## ► Estimateur sandwich

- Soit  $\bar{\theta}^{\text{VEM}} = \lim_{n \rightarrow \infty} L(\theta)$ , alors sous certaines conditions sur  $L$ ,


$$\sqrt{n}(\hat{\theta}^{\text{VEM}} - \theta^{\text{VEM}}) \xrightarrow{d} \mathcal{N}(0, V(\theta^{\text{VEM}}))$$

avec  $V(\theta) = C(\theta)^{-1}D(\theta)C(\theta)^{-1}$  et

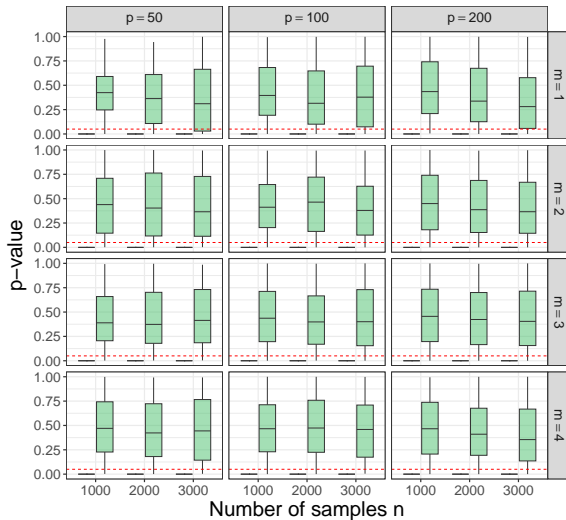
$$C(\theta) = \mathbb{E}[\nabla_{\theta\theta} L(\theta; Y)]$$

$$D(\theta) = \mathbb{E}[(\nabla_{\theta} L(\theta; Y))(\nabla_{\theta} L(\theta; Y))^{\top}]$$


## ► Simulations



# ► Simulations



# ► Application



## ► Limites et perspectives

### Limites

- Calcul de l'estimateur Sandwich laborieux
- Estimateur biaisé pour certains modèles

### Perspectives

- Automatisation de l'estimation de la variance (autograd, jax, functorch) à d'autres modèles PLN.
- Calcul pour d'autres paramètres que celui de la régression.



## ► Perspective

**i** Note

A note

**💡** Astuce

A tip

**!** Important

An important message



$$\begin{aligned}\operatorname{argmax} L(\theta) &\mapsto \operatorname{argmax} \log p_{\theta}(\mathbf{Y}) \\ \hat{\theta}^{VEM} &\mapsto \hat{\theta}^{MLE} \mapsto \theta^{\star}\end{aligned}$$