



PLN: beyond prediction and theory

LSD

Bastien Batardière

10 février 2025



LICENCE OUVERTE
OPEN LICENCE

► Aperçu

- Normalité asymptotique et inférence variationnelle
- Optimisation et inférence variationnelle

Section 1

Contexte et introduction

► Contexte

Données

$\mathbf{Y} \in \mathbb{R}^{n \times p}$: n individus \mathbf{Y}_i indépendants, de dimension p .

Modèle à variables latentes

$$\begin{aligned}\mathbf{Z}_i &\stackrel{\text{indep}}{\sim} p_{\theta}(\cdot) \\ Y_{ij} | \mathbf{Z}_i &\stackrel{\text{indep}}{\sim} p_{\theta}(\cdot | \mathbf{Z}_i)\end{aligned}$$

Vraisemblance

$$p_{\theta}(\mathbf{Y}_i) = \int_{\mathbb{R}^p} p_{\theta}(\mathbf{Y}_i, \mathbf{Z}_i) d\mathbf{Z}_i$$

► Modèle Poisson Log Normal

Modèle

- Etant donné des covariables :
 - \mathbf{x}_i covariables de taille m pour $i = \{1, \dots, n\}$ (longueur de la séquence d'ADN, température, etc)
- un paramètre $\theta = (\mathbf{B}, \Sigma)$:
 - $\mathbf{B} \in \mathbb{R}^{m \times p}$ un paramètre de régression
 - $\Sigma \in \mathcal{S}_p^{++}$ une matrice de covariance

$$\mathbf{Z}_i \stackrel{\text{indep}}{\sim} \mathcal{N}(\mathbf{x}_i^\top \mathbf{B}, \Sigma)$$
$$Y_{ij} | Z_{ij} \stackrel{\text{indep}}{\sim} \mathcal{P}(\exp\{Z_{ij}\})$$

► Enjeux

Maximisation de la log vraisemblance

$$\hat{\theta}^{\text{MLE}} = \operatorname{argmax}_{\theta} \log p_{\theta}(\mathbf{Y}) = \operatorname{argmax}_{\theta} \sum_{i=1}^n \log p_{\theta}(\mathbf{Y}_i)$$

- Comment approcher $\hat{\theta}^{\text{MLE}}$ efficacement ?
- Quelles garanties ?

Garanties de $\hat{\theta}^{\text{MLE}}$

$$\sqrt{n} \left(\hat{\theta}^{\text{MLE}} - \theta^{\star} \right) \xrightarrow{d} \mathcal{N}(0, \mathcal{I}(\theta^{\star})^{-1})$$

► Rappel sur l'inférence variationnelle

- Log vraisemblance intractable
 - Estimation problématique
 - Approche alternative: approximation
- Borne inférieure de la vraisemblance (ELBO) :

$$J_{\mathbf{Y}}(\theta, \phi) \triangleq \log p_{\theta}(\mathbf{Y}) - \text{KL} [\tilde{p}_{\phi}(\cdot) \| p_{\theta}(\cdot | \mathbf{Y})]$$

avec \tilde{p}_{ϕ} une distribution variationnelle connue approchant $p_{\theta}(\cdot | \mathbf{Y})$.

- Estimateur variationnel

$$\hat{\theta}^{\text{VEM}} = \operatorname{argmax}_{\theta, \phi} J_{\mathbf{Y}}(\theta, \phi)$$



► Algorithme VEM

- EM Variationnel (VEM) :
 - Maximisation alternée de $J_{\mathbf{Y}}(\theta, \phi)$.

Etape VE :

$$\phi^{(t)} = \operatorname{argmax}_{\phi} J_{\mathbf{Y}}(\theta^{(t)}, \phi)$$

Etape de maximisation (M) :

$$\theta^{(t+1)} = \operatorname{argmax}_{\theta} J_{\mathbf{Y}}(\theta, \phi^{(t)})$$

► Garanties de $\hat{\theta}^{\text{VEM}}$

► ELBO:

$$J_{\mathbf{Y}}(\theta, \phi) = \log p_{\theta}(\mathbf{Y}) - \text{KL} [\tilde{p}_{\phi}(\cdot) \| p_{\theta}(\cdot | \mathbf{Y})] \quad (1)$$

$$= \mathbb{E}_{\tilde{p}_{\phi}} [\log p_{\theta}(\mathbf{Y}, \mathbf{Z}) - \log \tilde{p}_{\phi}(\mathbf{Z})] \quad (2)$$


► Estimateur variationnel

$$\hat{\theta}^{\text{VEM}}, \hat{\phi} = \operatorname{argmax}_{\theta, \phi} J_{\mathbf{Y}}(\theta, \phi)$$


► Quelles garanties sur $\hat{\theta}^{\text{VEM}}$?

$$\sqrt{n} (\hat{\theta}^{\text{VEM}} - \theta^{\star}) \xrightarrow{d} ?$$

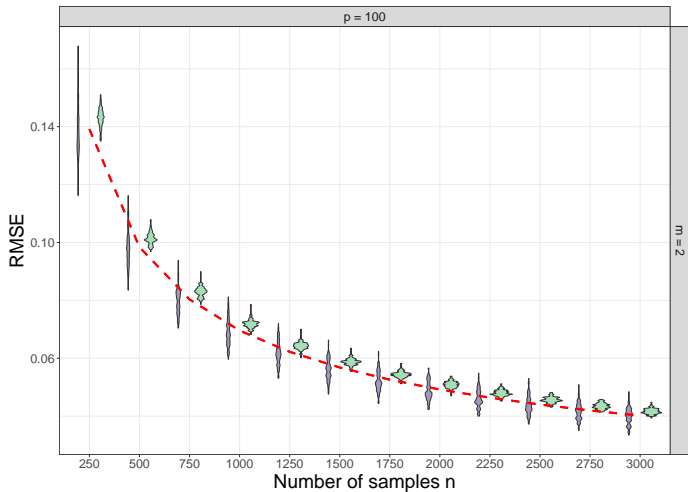
► Un peu d'intuition



► Estimateur biaisé ?



► Estimation du biais



INRAE

PLN: beyond prediction and theory
Bastien Batardière

--- $y = 2.2/\sqrt{n}$



$\text{RMSE}(\hat{B} - B^*)$



$\text{RMSE}(\hat{\Sigma} - \Sigma^*)$

Section 2

Estimateur de la variance

► Estimateur de la variance

Fonction objective profilé

$$L(\theta; \mathbf{Y}) \triangleq \sup_{\phi} J_{\mathbf{Y}}(\theta, \phi) = J_{\mathbf{Y}}(\theta, \hat{\phi})$$

► Estimateur naïf de la variance

- Pour l'estimateur du maximum de vraisemblance:

$$\sqrt{n} \left(\hat{\theta}^{\text{MLE}} - \theta^* \right) \xrightarrow{d} \text{mathcal{N}}(0, \mathcal{I}(\theta^*)^{-1})$$

- Si $\hat{\theta}^{\text{VEM}}$ est assez proche de θ^* , on peut approximer $\mathcal{I}(\theta^*)$ par $\mathcal{I}(\hat{\theta}^{\text{VEM}})$.

$$\begin{aligned} \mathcal{I}(\hat{\theta}^{\text{VEM}}) &\approx -\frac{1}{n} \nabla_{\theta}^2 \log p_{\theta}(\mathbf{Y}) \\ &\approx -\frac{1}{n} \nabla_{\theta}^2 L(\theta) \end{aligned}$$

► Estimateur sandwich

- Soit $\bar{\theta}^{\text{VEM}} = \lim_{n \rightarrow \infty} L(\theta)$, alors sous certaines conditions sur L ,


$$\sqrt{n}(\hat{\theta}^{\text{VEM}} - \theta^{\text{VEM}}) \xrightarrow{d} \mathcal{N}(0, V(\theta^{\text{VEM}}))$$

avec $V(\theta) = C(\theta)^{-1}D(\theta)C(\theta)^{-1}$ et

$$C(\theta) = \mathbb{E}[\nabla_{\theta\theta} L(\theta; Y)]$$

$$D(\theta) = \mathbb{E}[(\nabla_{\theta} L(\theta; Y))(\nabla_{\theta} L(\theta; Y))^{\top}]$$

► Simulations




INRAE


PLN: beyond prediction and theory
Bastien Batardière

● Variational Fisher Information ▲ Sandwich-based variance

► Simulations



► Application



► Callouts

i Note

A note

💡 Astuce

A tip

! Important

An important message



$$\begin{aligned}\operatorname{argmax} L(\theta) &\mapsto \operatorname{argmax} \log p_{\theta}(\mathbf{Y}) \\ \hat{\theta}^{VEM} &\mapsto \hat{\theta}^{MLE} \mapsto \theta^{\star}\end{aligned}$$